Détection de SMS frauduleux (Spam / Smishing) en français

Projet « Fouille de données textuelles » — Master 2 MAS (SDD), Université Rennes 2

Ce document résume la démarche suivie dans le notebook `projet_sms_spam.ipynb`, les choix réalisés et leur justification, ainsi que les résultats obtenus.

Contenu du dossier

Fichier	Rôle
`projet_sms_spam.ipynb`	Notebook principal : code commenté, résultats et analyses (étapes 1 à 5)
`telecharger_donnees.py`	Script qui télécharge les deux jeux de données depuis Hugging Face (déjà exécuté)
`data/sms_brut.csv`	**Données initiales n° 1** : Kinoux, 1 000 messages (`text`, `label`)
`data/sms_brut_2.csv`	**Données initiales n° 2** : SMS Spam Collection en français, 5 572 messages (`text`, `label`)
`data/sms_nettoye.csv`	**Données de sortie** : messages nettoyés (`source`, `text`, `text_masque`, `text_nettoye`, `label`)
`data/predictions_test.csv`	**Données de sortie** : prédictions du modèle final sur les 1 221 messages de test
`requirements.txt`	Bibliothèques Python nécessaires
`RESUME_PROJET.pdf`	Ce document

Consulter les résultats : le notebook est enregistré avec toutes ses sorties (tableaux, graphiques, scores). Il peut être lu sans rien installer.

Réexécuter le notebook (Jupyter doit être installé, durée d'environ 1 minute) :

```
pip install -r requirements.txt
python -m spacy download fr_core_news_md
jupyter notebook projet_sms_spam.ipynb   # puis « Exécuter tout »
```

Objectif

Classer automatiquement un message en **ham** (légitime) ou **spam** (publicité abusive, tentative de fraude ou d'hameçonnage par SMS, appelé *smishing*).

C'est un problème de **classification binaire supervisée** sur du texte court en français.

Étape 1 — Données et exploration

Deux jeux de données complémentaires

	Kinoux	SMS Spam Collection (traduite)
Source Hugging Face	`Kinoux/french-spam-ham-detection-free-2k`	`dbarbedillo/SMS_Spam_Multilingual_Collection_Dataset`
Contenu	Messages rédigés en français	Vrais SMS britanniques (UCI), **traduits automatiquement** en français
Ham	Surtout des **avis de clients**	De **vrais SMS personnels**
Spam	Publicité en ligne, phishing (compte bloqué…)	Concours, sonneries, numéros surtaxés (£)
Taille	1 000 messages, 50 % de spams	5 572 messages, dont 438 doublons ; 12,5 % de spams

Pourquoi combiner ? Une première version du projet, avec Kinoux seul, obtenait d'excellents scores, mais le modèle avait surtout appris à distinguer **un avis d'une publicité**, car les ham de Kinoux ne ressemblent pas à des SMS. Il classait par exemple « Tu peux acheter du pain en rentrant stp ? Merci ! » comme spam. La SMS Collection apporte de vrais échanges entre particuliers.

Constats

Constat	Conséquence
438 doublons dans la SMS Collection (publicités envoyées plusieurs fois)	Supprimés, pour qu'un même message ne soit pas à la fois dans l'apprentissage et dans le test
Corpus combiné **déséquilibré** : 18,7 % de spams	L'*accuracy* devient trompeuse. On évalue avec le **F1, la précision et le rappel** de la classe spam, et on compare deux corrections du déséquilibre
Montants en **£** et en pence, numéros surtaxés, sites en **.co.uk** dans les spams britanniques	Expressions régulières étendues à ces formats
Codes HTML (`&`, `<`) et **marqueurs d'anonymisation** (`<#>`, `<DECIMAL>`, `<TIME>`) dans certains SMS	Décodés et convertis (voir 2.A)
La proportion de spams **dépend de la source**	Découpage stratifié sur la classe **et** la source ; résultats aussi donnés par source

---

Étape 2 — Nettoyage et prétraitements linguistiques

2.A Masquage des entités (expressions régulières)

Balise	Exemples remplacés
`<URL>`	`https://bit.ly/2KXy9ZQ`, `www.textcomp.com`, `alto18.co.uk/wave`, adresses e-mail
`<PRIX>`	`1000€`, `50 euros`, `£250`, `150p`, `$$$`
`<POURCENT>`	`-70%`, `300%`
`<NUM>`	`06 12 34 56 78`, `09058097189`, codes SMS (`88877`), autres nombres

Pourquoi ? Sans masquage, le modèle apprendrait par cœur des détails (un nom de domaine, un montant précis). Avec les balises, il apprend la **structure** de l'arnaque : « gagnez **un montant** en appelant **un numéro** ». La balise `<PRIX>` est d'ailleurs devenue l'indicateur de spam le plus fort du modèle final.

Avant le masquage :

- **Marqueurs d'anonymisation** : les auteurs de la SMS Collection ont remplacé les nombres, heures et adresses des SMS personnels par `<#>`, `<DECIMAL>`, `<TIME>` … Ces marqueurs n'existent **que dans des ham** : les garder aurait donné au modèle un indice artificiel. On les convertit en `<NUM>` et `<URL>`, comme les vrais nombres et liens.
- **Mots collés** par une ponctuation ou une émoticône (`elle.je`, `oui:)ici`) : séparés.
- **Markdown** (`**gras**`), présent uniquement dans des spams : supprimé, car c'est une trace de la génération des corpus.

2.B Tokenisation, lemmatisation et stop-words (spaCy)

Modèle utilisé : `fr_core_news_md`, préféré au modèle `sm`, qui lemmatisait mal les verbes à l'impératif (*Découvrez* → *découvrir*).

1. **Tokenisation** : les balises (`<URL>`…) sont déclarées comme cas spéciaux pour ne pas être découpées.
2. **Lemmatisation** : *cliquez*, *CLIQUEZ*, *cliquer* deviennent **cliquer**.
3. **Formes collées** : spaCy découpe « est-ce » en *est* + *-ce* et « 150p/min » en … + */min*. On retire ces caractères de bord (*-ce* → *ce*, un stop-word ; *-vous* → *vous*). Avant cette correction, *-ce* était le 27e mot le plus fréquent du corpus.
4. **Stop-words** : retirés, **sauf** des mots utiles pour la tâche :
   - l'urgence : *maintenant* ;
   - la négation et la comparaison : *ne*, *pas*, *plus*, *moins* ;
   - l'adresse directe : *vous*, *votre*, *vos*.
5. **Ponctuation** : supprimée, **sauf « ! »**, plus fréquent dans les spams (1,15 par spam contre 0,41 par ham dans Kinoux ; 0,68 contre 0,14 dans la SMS Collection).

Avant	Après
Chère cliente, votre compte est bloqué ! Cliquez vite ici : https://… pour gagner 1000€, pas de frais.	cher client votre compte bloquer ! cliquer vite ici `<URL>` gagner `<PRIX>` pas frais

29 messages ham deviennent vides après nettoyage (ex. « Qu'est-ce que tu fais ? Comment vas-tu ? », uniquement des stop-words) et sont retirés. Il reste **6 105 messages** (4 965 ham, 1 140 spams).

Étape 3 — Représentation et modélisation

3.A Découpage et vectorisation TF-IDF

- **Découpage 80 / 20 stratifié sur la classe et la source** : 4 884 messages d'apprentissage, 1 221 de test (dont 228 spams).
- **TF-IDF** : un mot pèse lourd s'il est fréquent dans le message **et** rare dans le corpus. Réglages : `min_df=2`, `sublinear_tf=True`.
- **Pas de fuite de données** : le TF-IDF est placé dans un `Pipeline` avec le modèle, et n'est donc appris que sur les données d'apprentissage de chaque pli.

3.B Comparaison de quatre modèles

Recherche des hyperparamètres par `GridSearchCV`, **validation croisée stratifiée à 5 plis**, critère : **F1 de la classe spam**. La grille teste aussi uni-grams seuls / uni + bi-grams, et `class_weight` (`None` ou `'balanced'`).

Modèle	F1 (CV)	Précision	Rappel	AUC-ROC
Régression logistique	0,951 ± 0,016	0,967	0,936	0,994
k-NN (distance cosinus)	0,901 ± 0,012	0,956	0,852	0,967
SVM linéaire	**0,958 ± 0,014**	0,973	0,944	0,995
Random Forest	0,952 ± 0,009	0,986	0,921	0,994

(« ± » = écart-type du F1 sur les 5 plis : il mesure la stabilité du modèle.)

- **Modèle retenu : SVM linéaire** (C = 1, uni-grams seuls, sans `class_weight`). Il est pratiquement à égalité avec la Random Forest et la régression logistique : les écarts sont inférieurs aux écarts-types.
- Le **k-NN** est nettement moins bon : son rappel est faible (0,852), car un spam rédigé différemment des spams connus n'a pas de voisin proche.

3.C Déséquilibre des classes : `class_weight` ou SMOTE ?

SMOTE crée des spams artificiels dans l'espace TF-IDF (points intermédiaires entre deux spams voisins). Il est appliqué uniquement aux données d'apprentissage de chaque pli, grâce au `Pipeline` d'`imbalanced-learn`.

Variante (SVM, C = 1)	F1	Précision	Rappel
Sans correction	**0,958**	0,973	0,944
`class_weight='balanced'`	0,946	0,936	0,956
SMOTE	0,949	0,947	0,952

Les deux corrections **augmentent le rappel mais baissent davantage la précision**. Avec 1 spam pour 4 ham, le déséquilibre est modéré et le SVM le gère déjà : on garde le modèle sans correction. Si la priorité absolue était de ne laisser passer aucune arnaque, `class_weight='balanced'` serait préférable.

3.D Évaluation finale sur le jeu de test (1 221 messages jamais vus)

	Précision	Rappel	F1
ham	0,988	0,996	0,992
spam	0,982	0,947	**0,964**

- **AUC-ROC :** 0,995 ; **accuracy :** 0,987.
- **Matrice de confusion :** 989 ham bien classés, 216 spams détectés, **4 faux positifs** (vrais messages bloqués) et **12 faux négatifs** (spams non détectés).
- L'**accuracy (0,987) est supérieure au F1 spam (0,964)** : avec des classes déséquilibrées, l'accuracy est tirée vers le haut par les nombreux ham faciles. C'est pourquoi le F1 est le critère principal.

Par source :

Source	Messages de test	Précision	Rappel	F1
Kinoux	200	1,000	0,980	0,990
SMS Collection	1 021	0,967	0,922	0,944

Erreurs :

- **Faux positifs** : SMS légitimes qui ressemblent à de la publicité, tous avec un score faible (cas limites). Exemples : « C'est 6 £ pour entrer, c'est bon ? » (à cause de `<PRIX>`), « Textes illimités. Minutes limitées. ».
- **Faux négatifs** : spams courts ou sans montant ni lien. Exemples : « 2/2 146tf150p », « Vends bureau spacieux, affaires en or! ». 7 des 12 ont un score juste en dessous de la frontière (entre −0,3 et 0).

Coefficients du modèle :

- vers **spam** : `<PRIX>` (le plus fort), *découvrir*, *immédiatement*, `<URL>`, *gratuit*, *txt*, *votre*, *cliquer*, *alerte*, *!*, *sonnerie*. On retrouve les marqueurs du smishing : un gain, un lien, l'adresse directe et l'urgence ;
- vers **ham** : *excellent*, *hier*, *facture*, *prendre*, *aimer*, *devoir*, *savoir*. Le modèle s'appuie maintenant sur le vocabulaire de la **vie quotidienne**, et plus seulement sur celui de l'opinion. Quelques mots ne viennent que d'un seul message (*bedrm*, *ard*) : léger sur-apprentissage, sans effet sur les scores.

Étape 4 — Généralisation et nouveaux messages

4.A Expérience croisée : un modèle appris sur une source fonctionne-t-il sur l'autre ?

F1 de la classe spam, avec les réglages du modèle retenu :

Appris sur ↓ / testé sur →	Kinoux	SMS Collection
Kinoux seul	0,985	**0,640**
SMS Collection seul	**0,532**	0,956
Les deux	**0,990**	**0,944**

- Appris sur **Kinoux seul**, le modèle n'a qu'une **précision de 0,56** sur la SMS Collection : près de la moitié des messages qu'il bloque sont de vrais SMS.

- Appris sur la **SMS Collection seule**, il ne détecte qu'**un peu plus d'un tiers des spams de Kinoux** (rappel 0,37), car il ne connaît pas le phishing et la publicité en ligne.
- Le **modèle combiné réussit sur les deux**. Cette expérience **justifie la combinaison des deux jeux de données**, et montre qu'un score obtenu sur un seul corpus surestime les performances sur des messages d'un autre type.

4.B Test sur 12 messages écrits pour l'occasion

Une fonction `predire()` applique à un SMS brut toute la chaîne : masquage → spaCy → TF-IDF → SVM.

Groupe	Résultat
Smishing français actuels (colis, Ameli, CPF, amende ANTAI, banque)	**5 / 5 détectés**
SMS personnels légitimes	**5 / 5 corrects**
Avis de clients (témoin)	2 / 2 corrects

- « Tu peux acheter du pain en rentrant stp ? Merci ! », classé **spam** par le modèle Kinoux seul, est maintenant nettement classé **ham**.
- L'**amende ANTAI** est l'arnaque la moins nette (score 0,42) : ce type d'arnaque est absent des deux corpus.
- 12 messages ne sont qu'une indication, pas une évaluation statistique.

Étape 5 — Conclusion et limites

Bilan

En combinant deux corpus complémentaires et une chaîne de traitement simple (regex + spaCy + TF-IDF + SVM linéaire), on obtient un **F1 de 0,964** et une **AUC-ROC de 0,995** sur 1 221 messages de test. Surtout, le modèle **généralise** : il fonctionne sur les deux types de messages, alors qu'un modèle appris sur un seul corpus échoue sur l'autre. Il est interprétable : ses mots les plus influents correspondent aux marqueurs connus du smishing.

Limites

1. **Traduction automatique** : les messages de la SMS Collection gardent des abréviations anglaises (*u*, *txt*, *ur*) et des tournures maladroites.
2. **Spams datés et britanniques** (années 2000, £, numéros surtaxés). Les arnaques françaises récentes (colis, Ameli, CPF, amendes) sont absentes des corpus.
3. **Corpus Kinoux probablement généré automatiquement**, avec des ham composés d'avis de clients.
4. **Score du SVM** : c'est une distance à la frontière, pas une probabilité. Il faudrait le calibrer (`CalibratedClassifierCV`) pour obtenir une probabilité.

Pistes d'amélioration

- Ajouter des **smishing français récents** (signalements de Cybermalveillance.gouv.fr) et de **vrais SMS écrits en français** (corpus *88milSMS*).
- **Ajuster le seuil de décision** : 7 des 12 spams manqués sont juste en dessous de la frontière.
- Tester un modèle de langue français de type **CamemBERT**.